Universidade Estadual de Santa Cruz — UESC

Departamento de Ciências Exatas e Tecnológicas

GalaxyNet

Classificador Morfológico de Galáxias

Relatório Final — Aquisição de Dados, Pré-processamento e Modelos MLP, CNN e Híbrido com Grad-CAM

Disciplina: Deep Learning Aplicado à Astrofísica

Prof. André Ribeiro

22 de abril de 2026

Sumário

1 Resumo **2**

2 Introdução **3**

2.1 Contexto e Motivação 3

2.2 Objetivos 4

3 Metodologia **4**

3.1 Bancos de Dados Utilizados 4

3.2 Atribuição de Classes Morfológicas 6

3.3 Pré-processamento Tabular 7

3.4 Pré-processamento de Imagens 9

3.5 Partição dos Dados 10

3.6 Arquitetura dos Modelos 10

3.6.1 MLP 10

3.6.2 CNN 11

3.6.3 Modelo Híbrido 12

3.7 Treinamento 12

3.8 Métricas de Avaliação 13

3.9 Interpretabilidade via Grad-CAM 13

4 Resultados e Discussão **14**

4.1 Análise Exploratória dos Dados 14

4.2 Pré-processamento Aplicado 16

4.3 Desempenho dos Modelos 19

4.3.1 MLP 19

4.3.2 CNN 21

4.3.3 Modelo Híbrido 22

4.4 Análise Comparativa 24

4.5 Interpretabilidade 27

4.6 Galáxias Mal Classificadas 28

4.7 Limitações 29

5 Conclusão **30**

1 Resumo

Este relatório apresenta o projeto GalaxyNet, um *pipeline* completo de *deep learning* para classificação morfológica automática de galáxias a partir de dados do Sloan Digital Sky Survey (SDSS), *Data Release* 17, combinados com os rótulos supervisionados do Galaxy Zoo 2 (GZ2). O trabalho abrange a aquisição e o cruzamento dos catálogos, a análise exploratória dos dados, a engenharia de *features* tabulares, o pré-processamento das imagens astronômicas, a implementação de três arquiteturas de classificação — um Perceptron Multicamadas (MLP), uma Rede Neural Convolucional (CNN) e um Híbrido de fusão tardia —, a avaliação comparativa dos modelos e a análise de interpretabilidade por meio da técnica Grad-CAM. O catálogo final contém 9.054 galáxias, descritas por 15 *features* tabulares e por imagens de 64×64 pixels em três bandas fotométricas (g, r, i).

2 Introdução

2.1 Contexto e Motivação

Galáxias são sistemas gravitacionalmente ligados formados por estrelas, gás, poeira e matéria escura, com massas que variam de cerca de 10^7 a 10^{13} $M_\odot$. A diversidade de formas observadas entre galáxias, desde sistemas aproximadamente esféricos até discos com braços espirais proeminentes, reflete diferenças em suas histórias de formação, taxas de formação estelar e interações com o ambiente [14]. A morfologia de uma galáxia é, portanto, um registro observacional das condições físicas que governaram sua evolução.

A primeira tentativa sistemática de organizar essa diversidade foi a Sequência de Hubble [12], que classifica as galáxias em quatro grandes famílias: elípticas (E), lenticulares (S0), espirais (S) e irregulares (Irr). As elípticas apresentam perfis de brilho suaves, formação estelar negligenciável e dominam os centros de aglomerados ricos. As lenticulares possuem disco sem braços espirais e representam um estágio intermediário entre discos passivos e elípticas [19]. As espirais são discos com braços ativos em formação estelar. As irregulares apresentam morfologia assimétrica, frequentemente associada a interações ou episódios intensos de formação estelar. Trabalhos posteriores [13, 14] refinaram esse sistema com descrições quantitativas baseadas em concentração, assimetria e outros índices estruturais.

Uma das descobertas fundamentais da astronomia extragaláctica é a relação morfologia–densidade [17], segundo a qual ambientes densos favorecem galáxias elípticas e lenticulares, enquanto as espirais predominam no campo. Essa relação foi estendida a grupos [18] e verificada em altos *redshifts* com o *Hubble Space Telescope* [19], revelando que a transformação morfológica é um processo dependente tanto da massa da galáxia quanto do ambiente [21, 20, 15, 16]. Compreender e classificar morfologias é, portanto, um passo essencial em qualquer estudo da evolução galáctica.

A classificação visual por astrônomos especialistas, embora precisa, é inviável para o volume de dados dos levantamentos modernos. Catálogos como o de Nair & Abraham [22] cobriram cerca de 14.000 galáxias, uma fração ínfima dos mais de um milhão de galáxias disponíveis em surveys contemporâneos. O projeto Galaxy Zoo [23] inaugurou uma nova etapa ao empregar ciência cidadã, mobilizando mais de 100.000 voluntários para classificar visualmente cerca de 900.000 galáxias do SDSS, e demonstrou que o consenso coletivo alcança alta concordância com especialistas. O Galaxy Zoo 2 [24] estendeu esse esforço a classificações morfológicas detalhadas.

A próxima geração de levantamentos, como o *Legacy Survey of Space and Time* (LSST) do Observatório Vera C. Rubin, irá catalogar dezenas de bilhões de galáxias, tornando obrigatória a automação da classificação morfológica por meio de técnicas de aprendizado de máquina. O trabalho pioneiro de Dieleman, Willett & Dambre [7]

mostrou que CNNs podem prever diretamente as respostas do Galaxy Zoo a partir de imagens SDSS. Desde então, diversos estudos ampliaram o uso de *deep learning* em astronomia [25, 26, 27].

2.2 Objetivos

Neste contexto, o projeto GalaxyNet tem como objetivo construir um *pipeline* reprodutível de classificação morfológica de galáxias e comparar três arquiteturas de aprendizado profundo sobre o mesmo conjunto de dados. As arquiteturas consideradas são: o MLP, que utiliza apenas *features* tabulares derivadas de fotometria e espectroscopia; a CNN, que opera diretamente sobre as imagens das galáxias; e o Híbrido, que integra as duas modalidades por fusão tardia. O projeto também aplica a técnica Grad-CAM para verificar se as regiões de atenção do modelo correspondem a características morfológicas reconhecíveis, contribuindo para a interpretabilidade do classificador.

3 Metodologia

3.1 Bancos de Dados Utilizados

Os dados fotométricos e espectroscópicos foram obtidos a partir do Sloan Digital Sky Survey (SDSS), *Data Release* 17 (DR17), um dos levantamentos astronômicos mais extensos já realizados. A consulta foi executada por meio da biblioteca `astroquery.sdss`, em modo *all-sky*, unindo as tabelas `PhotoObj` (fotometria) e `SpecObj` (espectroscopia), com filtros de qualidade aplicados para selecionar objetos classificados como galáxias, com fotometria limpa, magnitude r dentro da faixa de completeza espectroscópica ($14{,}0 \leq r \leq 17{,}77$), *redshift* entre 0,02 e 0,25 e sem alertas de qualidade espectroscópica. A consulta retornou 50.000 registros, dos quais 9.054 foram cruzados com o Galaxy Zoo 2. As colunas utilizadas estão listadas na Tabela 1.

Tabela 1: Colunas recuperadas da consulta ao SDSS DR17.

Coluna	**Tipo**	**Descrição**
`objid`	ID	Identificador único do objeto no SDSS
`ra, dec`	Posição	Ascensão reta e declinação (graus)
`u, g, r, i, z`	Fotometria	Magnitudes nas cinco bandas ópticas
`petroRad_r`	Estrutural	Raio de Petrosian na banda r
`petroR50_r`	Estrutural	Raio contendo 50% do fluxo Petrosian
`petroR90_r`	Estrutural	Raio contendo 90% do fluxo Petrosian
`deVAB_r`	Estrutural	Razão axial (perfil de Vaucouleurs)
`expAB_r`	Estrutural	Razão axial (perfil exponencial)
`lnLDeV_r`	Ajuste	Log-verossimilhança do perfil de Vaucouleurs
`lnLExp_r`	Ajuste	Log-verossimilhança do perfil exponencial
`lnLStar_r`	Ajuste	Log-verossimilhança do perfil estelar
`fracDeV_r`	Estrutural	Fração de fluxo do perfil de Vaucouleurs
`redshift`	Espectro	*Redshift* espectroscópico
`zErr`	Espectro	Incerteza no *redshift*
`velDisp`	Espectro	Dispersão de velocidades estelar (km/s)
`velDispErr`	Espectro	Incerteza na dispersão de velocidades

Os rótulos morfológicos foram obtidos do Galaxy Zoo 2 (GZ2), por meio do arquivo `gz2_hart16.csv` [1]. O GZ2 fornece frações de votos de voluntários para diferentes características morfológicas, conforme mostra a Tabela 2.

Tabela 2: Frações de votos do Galaxy Zoo 2 utilizadas na atribuição de classes.

Coluna GZ2	**Significado**
`t01_.._a01_smooth_fraction`	Fração de votos "galáxia lisa"
`t01_.._a02_features_fraction`	Fração de votos "disco / feições"
`t01_.._a03_star_fraction`	Fração de votos "estrela / artefato"
`t03_bar_a06_bar_fraction`	Fração de votos "barra presente"
`t04_spiral_a08_spiral_fraction`	Fração de votos "braços espirais"
`total_votes_gz2`	Total de votos por galáxia

Como o GZ2 foi construído sobre o SDSS DR7, enquanto os dados fotométricos provêm do DR17, os identificadores de objeto dos dois catálogos não são diretamente compatíveis. Para contornar essa incompatibilidade adotou-se o cruzamento espacial por coordenadas (*sky cross-match*), implementado com a função `match_to_catalog_sky`

da biblioteca `astropy`. A tolerância de 1 arcsec, padrão em aplicações astronômicas, garante associações únicas sem ambiguidade, considerando o *seeing* típico do SDSS ($\approx$ 1,4 arcsec).

```
sdss_coords = SkyCoord(ra=sdss_df['ra'].values * u.deg,
                       dec=sdss_df['dec'].values * u.deg)
gz2_coords  = SkyCoord(ra=gz2_df['gz2_ra'].values * u.deg,
                       dec=gz2_df['gz2_dec'].values * u.deg)

idx, sep2d, _ = sdss_coords.match_to_catalog_sky(gz2_coords)
mask = sep2d.arcsec <= 1.0   # separação máxima: 1 arcsec
```

Listing 1: Cruzamento espacial entre SDSS e GZ2.

3.2 Atribuição de Classes Morfológicas

A partir das frações de votos do GZ2, cada galáxia recebeu uma das classes morfológicas segundo a lógica descrita na Tabela 3. Foram exigidos pelo menos 20 votos por galáxia e uma fração mínima de 0,8 para a característica dominante. Galáxias que não satisfazem esses critérios são descartadas como `Uncertain`.

Tabela 3: Regras de atribuição de classe morfológica.

Classe	**Condição**
`Elliptical`	$f_{\text{smooth}} \geq 0{,}8$ e $f_{\text{features}} < 0{,}8$
`Lenticular`	$f_{\text{smooth}} \geq 0{,}8$ e $f_{\text{features}} \geq 0{,}8$
`Spiral`	$f_{\text{features}} \geq 0{,}8$ e $f_{\text{spiral}} \geq 0{,}8$
`Irregular`	$f_{\text{features}} \geq 0{,}8$ e $f_{\text{spiral}} < 0{,}8$
`Uncertain`	Nenhuma condição acima satisfeita, ou $N_{\text{votos}} < 20$

O catálogo final contém 9.054 galáxias distribuídas entre as classes conforme a Tabela 4. Observa-se um desbalanceamento significativo, característico de amostras fotométricas brilhantes do SDSS, no qual as galáxias elípticas dominam em mais de 80% do total. Esse desbalanceamento precisa ser tratado durante o treinamento dos modelos.

Tabela 4: Distribuição de classes no catálogo final.

Classe	N	**Proporção (%)**
Elliptical	7.595	83,9
Spiral	1.198	13,2
Irregular	261	2,9
Total	**9.054**	**100,0**

3.3 Pré-processamento Tabular

O pré-processamento tabular foi implementado no módulo `src/preprocessing.py` e executado no notebook `notebooks/02_preprocessing.ipynb`. A partir das magnitudes brutas, cinco *features* derivadas foram adicionadas ao catálogo (Tabela 5). Essas variáveis têm significado físico bem estabelecido: os índices de cor descrevem a população estelar dominante, e o índice de concentração $C = R_{90}/R_{50}$ é um estimador clássico da morfologia galáctica [2].

Tabela 5: Features derivadas criadas durante o pré-processamento tabular.

Feature	**Fórmula**	**Interpretação física**
`u_g`	$u - g$	Cor UV-óptico; alto em galáxias velhas
`g_r`	$g - r$	Principal discriminador elíptica/espiral
`r_i`	$r - i$	Cor óptico-NIR próximo
`i_z`	$i - z$	Cor NIR próximo
`concentration`	R_{90}/R_{50}	Concentração de luz; elípticas: $C > 3$, espirais: $C < 3$

O conjunto final de 15 *features* tabulares utilizadas pelo MLP e pelo ramo tabular do Híbrido está listado na Tabela 6. Colunas de identificação, coordenadas e frações de votos do GZ2 foram excluídas para evitar vazamento de informação.

Tabela 6: Conjunto final de 15 *features* tabulares (`TABULAR_FEATURES`).

Grupo	**Features**	**Qtd.**
Magnitudes brutas	`u, g, r, i, z`	5
Índices de cor	`u_g, g_r, r_i, i_z`	4
Espectroscópicos	`redshift, velDisp`	2
Morfológicos/estruturais	`concentration, deVAB_r, expAB_r, fracDeV_r`	4
Total		**15**

A normalização foi realizada com o `StandardScaler` do `scikit-learn`, que transforma cada *feature* x_j segundo:

$$\tilde{x}_j = \frac{x_j - \mu_j}{\sigma_j} \tag{1}$$

As médias μ_j e os desvios-padrão σ_j são calculados apenas sobre o conjunto de treino, e o *scaler* ajustado é serializado para ser reaplicado sobre os conjuntos de validação e teste, evitando vazamento de informação.

```
scaler   = StandardScaler()
X_scaled = scaler.fit_transform(X_train)   # fit apenas no treino
X_val    = scaler.transform(X_val)         # apenas transform no val
X_test   = scaler.transform(X_test)        # apenas transform no teste
```

Listing 2: Escalonamento das *features* tabulares.

Para mitigar o desbalanceamento entre classes, foram utilizados pesos balanceados (*class weights*) calculados via a função `compute_class_weight` do `scikit-learn`. O peso de cada classe c é dado por:

$$w_c = \frac{N_{\text{total}}}{K \cdot N_c} \tag{2}$$

onde N_{total} é o número total de amostras no treino, K é o número de classes e N_c é o número de amostras da classe c. Cada amostra de uma classe minoritária contribui proporcionalmente mais para a função de perda, incentivando o modelo a não ignorá-la.

```
from sklearn.utils.class_weight import compute_class_weight

weights = compute_class_weight('balanced',
    classes=np.unique(y_train_int), y=y_train_int)
class_weight_dict = dict(enumerate(weights))

model.fit(X_train, y_train, class_weight=class_weight_dict, ...)
```

Listing 3: Cálculo e aplicação dos *class weights*.

3.4 Pré-processamento de Imagens

As imagens FITS foram baixadas do SDSS DR17 via a função `download_galaxy_image_cutout` em `src/data_loader.py`, que utiliza a classe `Cutout2D` do `astropy` para extrair recortes centrados na posição de cada galáxia. Cada imagem é armazenada como um array `float32` de forma $(64, 64, 3)$, com os três canais correspondentes às bandas fotométricas g, r e i.

O *pipeline* de normalização é implementado na função `preprocess_galaxy_image` e aplica, canal a canal, três transformações sequenciais. A primeira é o *arcsinh stretch*,

$$\hat{x} = \operatorname{arcsinh}\left(\frac{x}{\alpha}\right), \tag{3}$$

com α (`stretch_factor`) igual a 1000. A função arcsinh é aproximadamente linear para valores pequenos e logarítmica para valores grandes, realçando feições tênues como braços espirais e o envelope externo sem saturar a região central da galáxia. A normalização arcsinh é padrão em *pipelines* de imagens astronômicas [4]. A segunda etapa é um escalonamento min-max que mapeia cada canal ao intervalo $[0, 1]$:

$$x' = \frac{\hat{x} - \min(\hat{x})}{\max(\hat{x}) - \min(\hat{x})}. \tag{4}$$

A terceira etapa é o redimensionamento para o tamanho-alvo 64×64 pixels, realizado com o método `cv2.INTER_AREA`, que implementa média por blocos e é preferível ao `INTER_LINEAR` para *downscaling*, pois preserva a energia total da imagem.

```python
def preprocess_galaxy_image(image_data, target_size=(64,64),
    stretch_factor=1000):
    if image_data is None:
        return None
    normalized_channels = []
    for i in range(image_data.shape[-1]):
        channel  = image_data[:, :, i]
        stretched = np.arcsinh(channel / stretch_factor)
        ch_min, ch_max = stretched.min(), stretched.max()
        if ch_max - ch_min > 0:
            stretched = (stretched - ch_min) / (ch_max - ch_min)
        else:
            stretched = np.zeros_like(stretched)
        normalized_channels.append(stretched)
    normalized_image = np.stack(normalized_channels, axis=-1)
    resized = cv2.resize(normalized_image,
                         (target_size[1], target_size[0]),
                         interpolation=cv2.INTER_AREA)
    return resized.astype(np.float32)
```

Listing 4: Implementação do pipeline de pré-processamento de imagens.

3.5 Partição dos Dados

O conjunto foi dividido em três partições com estratificação por classe, de modo a preservar a proporção original em cada subconjunto: 70% para treino, 15% para validação e 15% para teste. A partição é realizada por índices compartilhados, de modo que a mesma galáxia permanece no mesmo subconjunto em todas as modalidades, permitindo comparações consistentes entre os modelos.

3.6 Arquitetura dos Modelos

Três modelos foram implementados em `src/models.py`, usando a API do `tf.keras`. Os três utilizam ativação ReLU nas camadas ocultas, *softmax* na saída, função de perda *categorical crossentropy* e otimizador Adam com *learning rate* inicial $\eta = 10^{-3}$ [8]. Os rótulos são codificados em representação *one-hot* (Elliptical $\rightarrow$ 0, Irregular $\rightarrow$ 1, Spiral $\rightarrow$ 2).

3.6.1 MLP

O MLP utiliza apenas as 15 *features* tabulares. Sua arquitetura, detalhada na Tabela 7, é composta por três blocos ocultos em estrutura piramidal (256 $\rightarrow$ 128 $\rightarrow$ 64), cada um seguido de `BatchNormalization` e `Dropout`. A redução progressiva da largura força o modelo a extrair representações mais compactas, e a `BatchNormalization` estabiliza o treinamento ao normalizar as ativações de cada camada dentro do *mini-batch*. As taxas de `Dropout` (0,3 nas primeiras camadas e 0,2 na terceira) foram definidas de forma decrescente, reduzindo a regularização à medida que a representação se torna mais compacta.

Tabela 7: Arquitetura do modelo MLP.

Camada	**Ativação**	**Neurônios**	**Dropout**
Input	—	15	—
Dense + BN	ReLU	256	0,3
Dense + BN	ReLU	128	0,3
Dense + BN	ReLU	64	0,2
Dense (saída)	Softmax	3	—

3.6.2 CNN

A CNN opera sobre as imagens $(64, 64, 3)$ e é composta por quatro blocos convolucionais com filtros crescentes ($32 \to 64 \to 128 \to 256$), seguidos por uma cabeça classificadora densa (Tabela 8). Cada bloco aplica `Conv2D` com *kernel* 3×3 e *padding same*, seguida de `BatchNormalization`, `MaxPooling2D` 2×2 e `Dropout` de 0,25. A progressão geométrica de filtros e o *kernel* 3×3 seguem o padrão consolidado desde a arquitetura VGGNet [10]. A camada `Dense(512)` na cabeça classificadora é acompanhada de `Dropout` de 0,5, conforme recomendado por Srivastava et al. [11], para reduzir o risco de *overfitting*, uma vez que essa camada concentra a maior parte dos parâmetros do modelo.

Tabela 8: Arquitetura do modelo CNN.

Bloco	**Camada**	**Filtros**	**Kernel**	**Dropout**
Input	—	—	—	—
1	Conv2D + BN + MaxPool	32	3×3	0,25
2	Conv2D + BN + MaxPool	64	3×3	0,25
3	Conv2D + BN + MaxPool	128	3×3	0,25
4	Conv2D + BN + MaxPool	256	3×3	0,25
Head	Flatten $\to$ Dense + BN	512	—	0,50
Saída	Dense (softmax)	3	—	—

A sequência de quatro blocos com *pooling* 2×2 reduz a resolução de 64×64 para 4×4, mantendo 256 canais ao final. Durante o treinamento foram aplicadas transformações de *data augmentation* em tempo real, descritas na Tabela 9. Como as galáxias não possuem orientação preferencial no plano do céu, transformações como rotação arbitrária e espelhamentos são fisicamente justificadas.

Tabela 9: Transformações de *data augmentation* aplicadas às imagens.

Transformação	**Valor**	**Justificativa física**
Rotação	360ř	Qualquer ângulo é válido no plano do céu
Flip horizontal	Sim	Simetria por reflexão do céu
Flip vertical	Sim	Simetria por reflexão do céu
Zoom	[0,8; 1,2]	Simula variações de distância angular
Brilho	[0,8; 1,2]	Simula variações de exposição
Fill mode	`constant` (0,0)	Bordas preenchidas com céu escuro

3.6.3 Modelo Híbrido

O Híbrido implementa uma estratégia de fusão tardia (*late fusion*) que combina as representações aprendidas de forma independente pelo ramo CNN (imagens) e pelo ramo MLP (*features* tabulares). Cada modalidade é processada por um ramo especializado, cujas saídas são concatenadas e passadas por uma camada densa de fusão, conforme descrito na Tabela 10. Na fusão tardia, cada modalidade é processada por um caminho adaptado à sua estrutura: a CNN extrai padrões visuais e o MLP aprende relações entre grandezas físicas, enquanto a camada final aprende a combinar essas duas perspectivas.

Tabela 10: Detalhamento dos ramos do Híbrido.

Ramo	**Saída**	**Arquitetura**
CNN (imagens)	256	4 blocos Conv2D(3x3)/BN/MaxPool/Dropout(0,25) com filtros 32→64→128→256, Flatten → Dense(256)/BN/Dropout(0,5)
MLP (tabular)	64	Dense(128)/BN/Dropout(0,3) → Dense(64)/BN/Dropout(0,3)
Fusão	3	Concatenate(256+64=320) → Dense(128)/ReLU/BN/Dropout(0,5) → Dense(3, softmax)

O ramo CNN do Híbrido é análogo à CNN independente, mas sua saída densa tem 256 neurônios em vez de 512, pois a representação visual é complementada pelas *features* tabulares na fusão. O ramo MLP produz uma saída de 64 dimensões, compatível com a menor dimensionalidade intrínseca das *features* tabulares. A concatenação gera um vetor de 320 dimensões, que alimenta uma camada densa de 128 neurônios com `Dropout` de 0,5 antes da camada final *softmax*. Um gerador customizado de dados (`hybrid_generator`) assegura que a *data augmentation* seja aplicada apenas às imagens, já que as *features* tabulares correspondem a grandezas físicas medidas e não devem ser perturbadas aleatoriamente.

3.7 Treinamento

Os três modelos foram treinados por até 100 épocas, com `batch_size` igual a 32. Dois *callbacks* controlaram automaticamente o processo de treinamento: `EarlyStopping`, monitorando a perda de validação e restaurando os melhores pesos após um número configurável de épocas sem melhora; e `ReduceLROnPlateau`, que reduz o *learning rate* pela metade quando a perda de validação estagna, até um valor mínimo de 10^{-7}. Para o MLP foi utilizada paciência de 10 épocas no `EarlyStopping` e 5 no `ReduceLROnPlateau`.

Para a CNN e o Híbrido, esses valores foram elevados para 15 e 7 épocas, respectivamente, considerando a maior variabilidade introduzida pela *data augmentation* e o maior número de parâmetros a otimizar.

Os *class weights* balanceados foram aplicados a todos os modelos durante o treinamento. No Híbrido, o split de treino, validação e teste é o mesmo da CNN e do MLP, com as mesmas galáxias em cada partição, de modo a permitir comparação direta dos três modelos no conjunto de teste.

3.8 Métricas de Avaliação

A avaliação dos modelos foi realizada pela função `evaluate_galaxy_classifier` definida em `src/evaluation.py`, que produz o *classification report* (precisão, revocação e F1-escore por classe), a matriz de confusão, e as métricas completeza e confiabilidade por classe morfológica, padrão em astronomia observacional [1]. A completeza, equivalente ao revocação, é definida como $C_c = \mathrm{TP}_c/(\mathrm{TP}_c + \mathrm{FN}_c)$ e mede a fração de objetos de uma classe corretamente identificados pelo modelo. A confiabilidade, equivalente à precisão, é dada por $R_c = \mathrm{TP}_c/(\mathrm{TP}_c + \mathrm{FP}_c)$ e mede a pureza da classificação. Também são reportadas acurácia, F1-macro (que atribui peso igual a cada classe) e F1 ponderado (ponderado pelo suporte de cada classe).

3.9 Interpretabilidade via Grad-CAM

Para avaliar se o Híbrido concentra sua atenção em regiões astrofisicamente relevantes, aplicou-se a técnica *Gradient-weighted Class Activation Mapping* (Grad-CAM) [5] sobre a última camada convolucional do ramo CNN. Formalmente, para a classe c e os *feature maps* $A^k \in \mathbb{R}^{H \times W}$ da camada alvo, os pesos de importância de cada canal k são calculados como a média global dos gradientes:

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k} \tag{5}$$

onde y^c é o *logit* da classe c e $Z = H \times W$ é o número de posições do *feature map*. O mapa de calor final é a combinação linear ponderada dos *feature maps*, com aplicação de ReLU para manter apenas contribuições positivas:

$$L_{\text{Grad-CAM}}^c = \mathrm{ReLU}\left(\sum_k \alpha_k^c \, A^k \right) \tag{6}$$

A implementação em `src/visualization.py` utiliza `tf.GradientTape` para computar os gradientes. A função `compute_gradcam_hybrid` recebe ambas as entradas (tabular e imagem) e retorna o mapa de calor normalizado em $[0, 1]$, que pode ser

sobreposto à imagem original para visualização.

4 Resultados e Discussão

4.1 Análise Exploratória dos Dados

O catálogo final contém 9.054 galáxias, todas com medições válidas nas 15 *features* usadas no treinamento e sem valores ausentes nas colunas de interesse. As magnitudes na banda r ficam na faixa $14{,}0 \leq r \leq 17{,}69$, e o *redshift* espectroscópico varia entre 0,02 e 0,20, com mediana de 0,083 e média de 0,088. A amostra se concentra, portanto, no universo próximo, com resolução angular adequada à análise morfológica nas imagens do SDSS.

A Figura 1 mostra o desbalanceamento entre as três classes: 83,9% da amostra é formada por galáxias elípticas, 13,2% por espirais e apenas 2,9% por irregulares. Esse padrão é esperado em amostras limitadas por magnitude, pois as galáxias elípticas massivas, por serem mais luminosas, são detectadas com mais frequência. As distribuições de *redshift* na Figura 2 se sobrepõem entre as três classes, com um pequeno deslocamento das elípticas para valores maiores de z, em linha com o viés de Malmquist. Sozinho, porém, o *redshift* tem pouco poder discriminante.

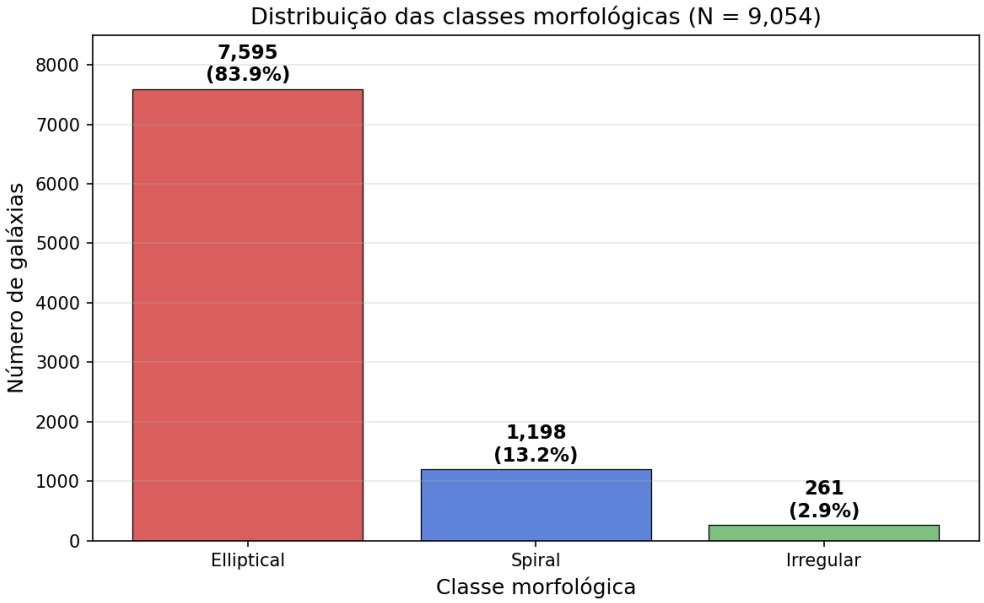

Figura 1: Distribuição das galáxias do catálogo por classe morfológica.

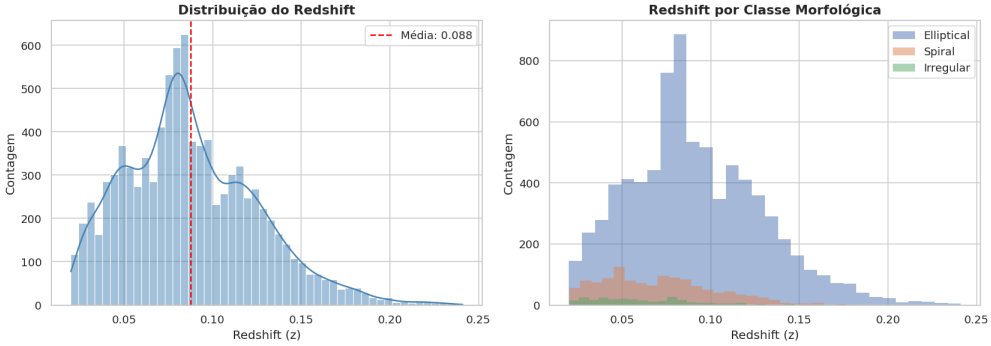

Figura 2: Distribuição do *redshift* espectroscópico por classe morfológica.

A matriz de correlação entre as variáveis do catálogo, mostrada na Figura 3, apresenta relações já esperadas. As magnitudes em bandas adjacentes são quase colineares, com $|\rho| > 0{,}98$, pois o brilho global domina sobre as diferenças de cor. Os raios Petrosianos `petroR50` e `petroR90` apresentam correlação negativa moderada com as magnitudes, com ρ entre $-0{,}5$ e $-0{,}7$, o que confirma que galáxias mais luminosas tendem a ser maiores. A dispersão de velocidades estelar `velDisp` tem correlação positiva com os índices de cor, com ρ entre 0,67 e 0,69, em linha com a relação conhecida entre massa estelar, profundidade do poço de potencial e idade das populações estelares: galáxias mais massivas tendem a ser mais vermelhas. A correlação entre *redshift* e magnitudes brutas é fraca, o que indica que o corte em magnitude limita o efeito de Malmquist sobre as variáveis usadas.

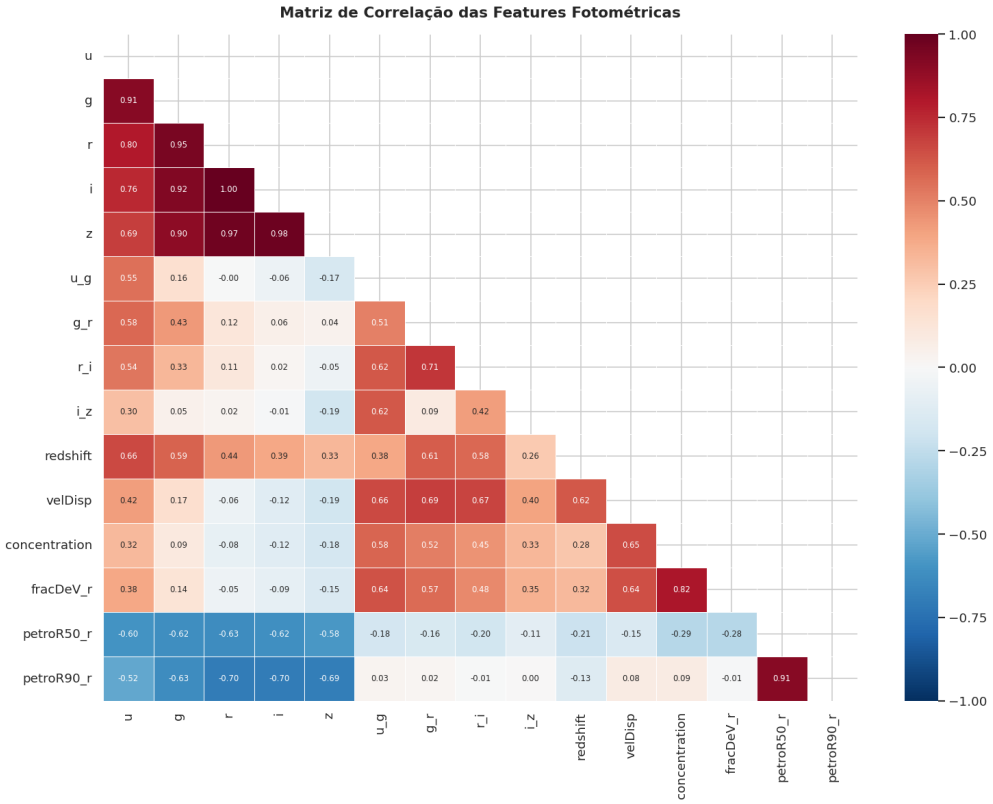

Figura 3: Matriz de correlação entre as variáveis do catálogo.

4.2 Pré-processamento Aplicado

Os índices de cor derivados, apresentados na Figura 4, confirmam que $g - r$ é a combinação que melhor separa espirais de elípticas, enquanto $i - z$ apresenta distribuições quase iguais entre as três classes, com poder discriminante muito baixo. O diagrama cor-concentração da Figura 5 mostra o mesmo comportamento em duas dimensões. As elípticas tendem a ocupar a região superior-direita, com cores mais vermelhas e perfis mais concentrados, mas a sobreposição entre classes continua alta, em especial perto das linhas $g - r = 0{,}7$ e $C = 3{,}0$. Nenhum corte binário em apenas duas variáveis tabulares, portanto, gera uma separação limpa.

Entre as cinco *features* estruturais derivadas, o índice de concentração $C = R_{90}/R_{50}$ é a variável que mais separa as classes individualmente. As medianas são $C \approx 2{,}97$ para elípticas, 2,70 para irregulares e 2,27 para espirais, seguindo a ordem esperada: quanto maior a dominância do bulge central, maior o valor de C. Os intervalos interquartílicos ainda se sobrepõem em parte, mas o deslocamento entre medianas é suficiente para que a concentração esteja entre as variáveis mais úteis para a classificação.

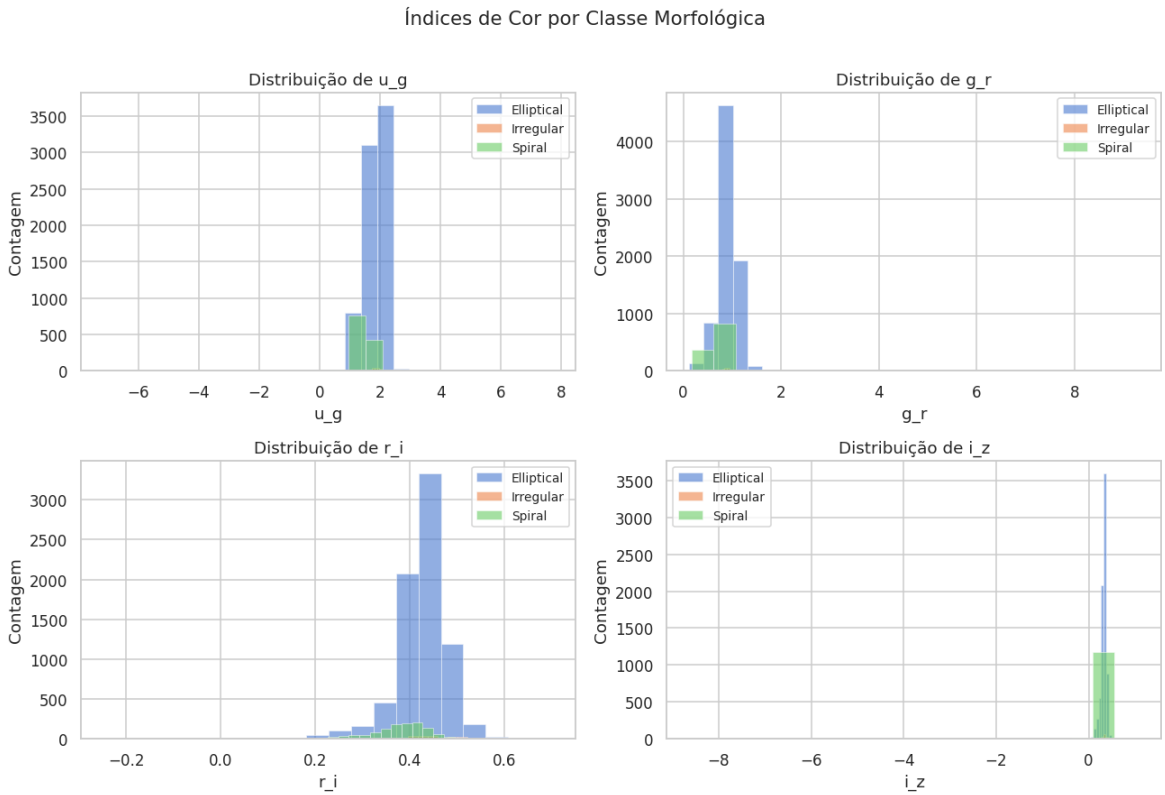

Figura 4: Distribuição dos índices de cor por classe morfológica. As galáxias elípticas apresentam cores consistentemente mais vermelhas.

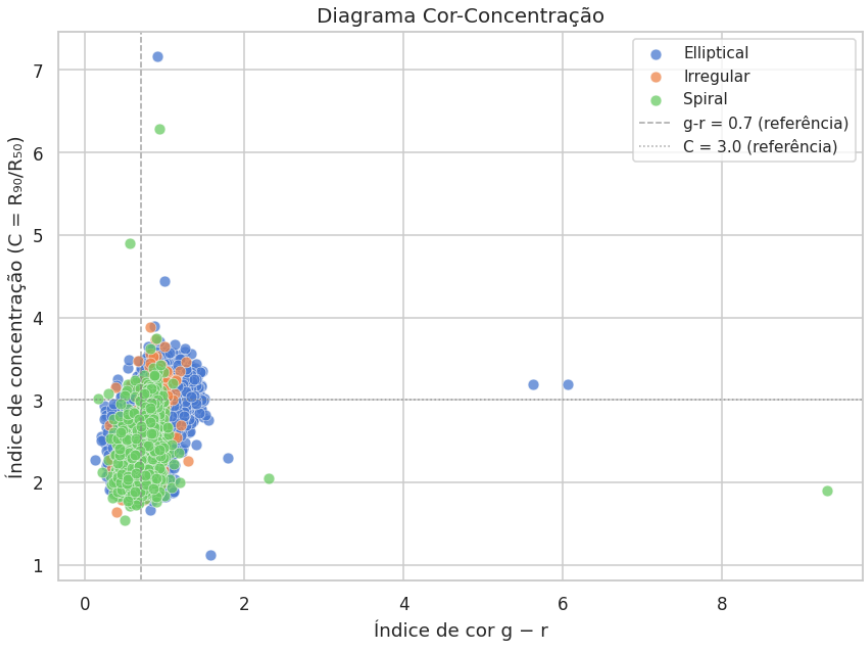

Figura 5: Diagrama cor-concentração ($g - r$ *vs.* $C = R_{90}/R_{50}$). As linhas tracejadas marcam os valores de referência $g - r = 0{,}7$ e $C = 3{,}0$.

A matriz de correlação entre as 15 *features* tabulares, mostrada na Figura 6, evidencia

a alta colinearidade entre as magnitudes brutas e os índices de cor construídos a partir delas. Dois blocos adicionais aparecem na matriz. O par `deVAB_r`/`expAB_r` apresenta redundância quase total, com $\rho \approx 0{,}98$. A correlação entre `fracDeV_r` e a concentração é de $\rho \approx 0{,}82$, e ambas as variáveis estão associadas à dominância do perfil de De Vaucouleurs no interior da galáxia. A variável `velDisp` mantém correlação próxima de 0,7 com o índice $g - r$, o que reforça a relação cor-massa. O `StandardScaler` aplicado antes do treinamento equaliza as escalas das variáveis, mas não remove a colinearidade; as camadas densas dos modelos absorvem essa redundância durante o aprendizado.

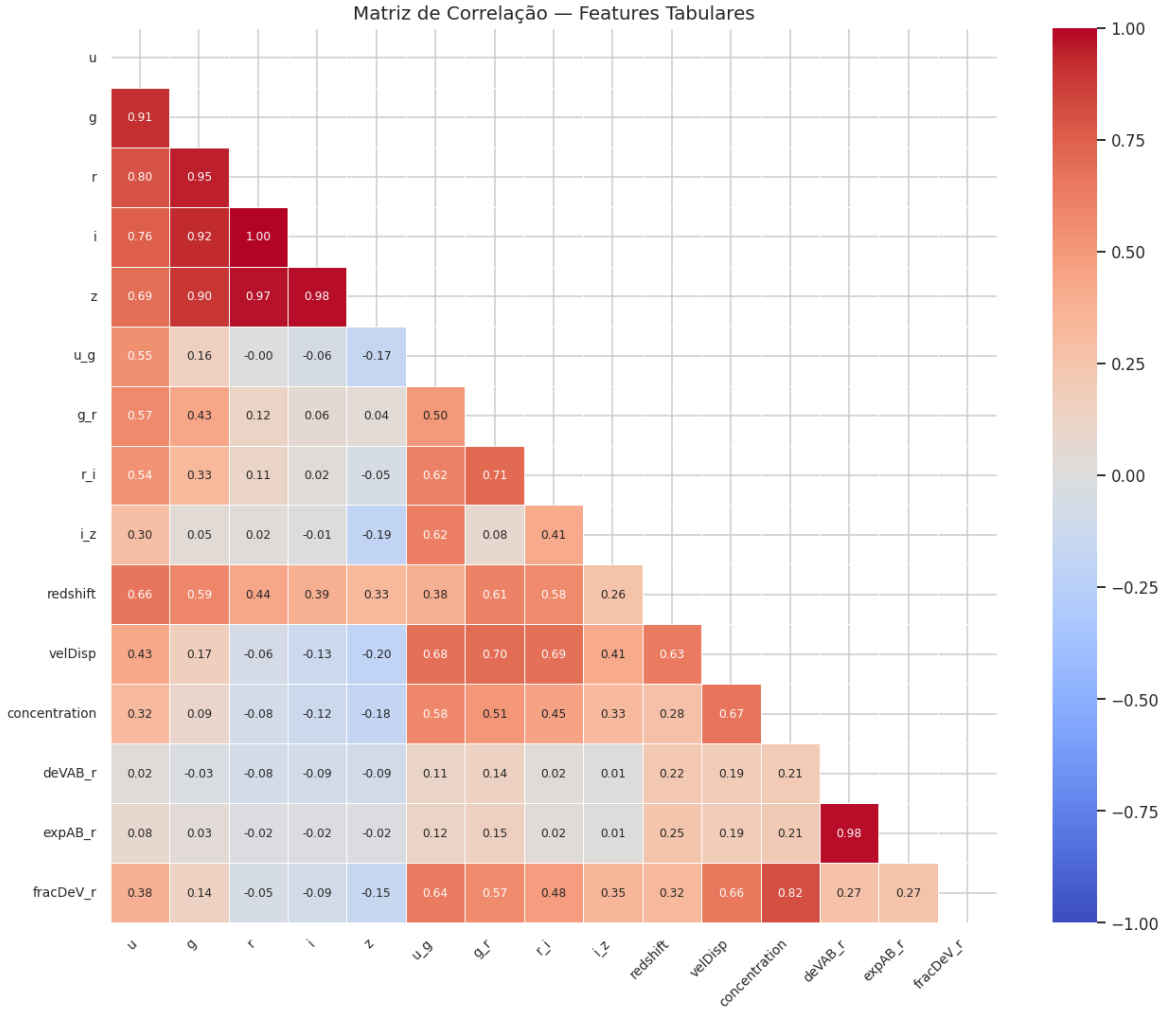

Figura 6: Matriz de correlação de Pearson entre as 15 *features* tabulares.

A Figura 7 traz um conjunto de imagens já pré-processadas em composição RGB falsa-cor, na qual a banda r é mapeada no canal vermelho, g no verde e i no azul. Com o *arcsinh stretch* e a normalização por canal, as diferenças morfológicas entre as classes ficam visíveis: as elípticas têm perfil suave e simetria aproximada, as espirais mostram disco estendido com subestruturas internas, e as irregulares apresentam morfologias fragmentadas e assimétricas.

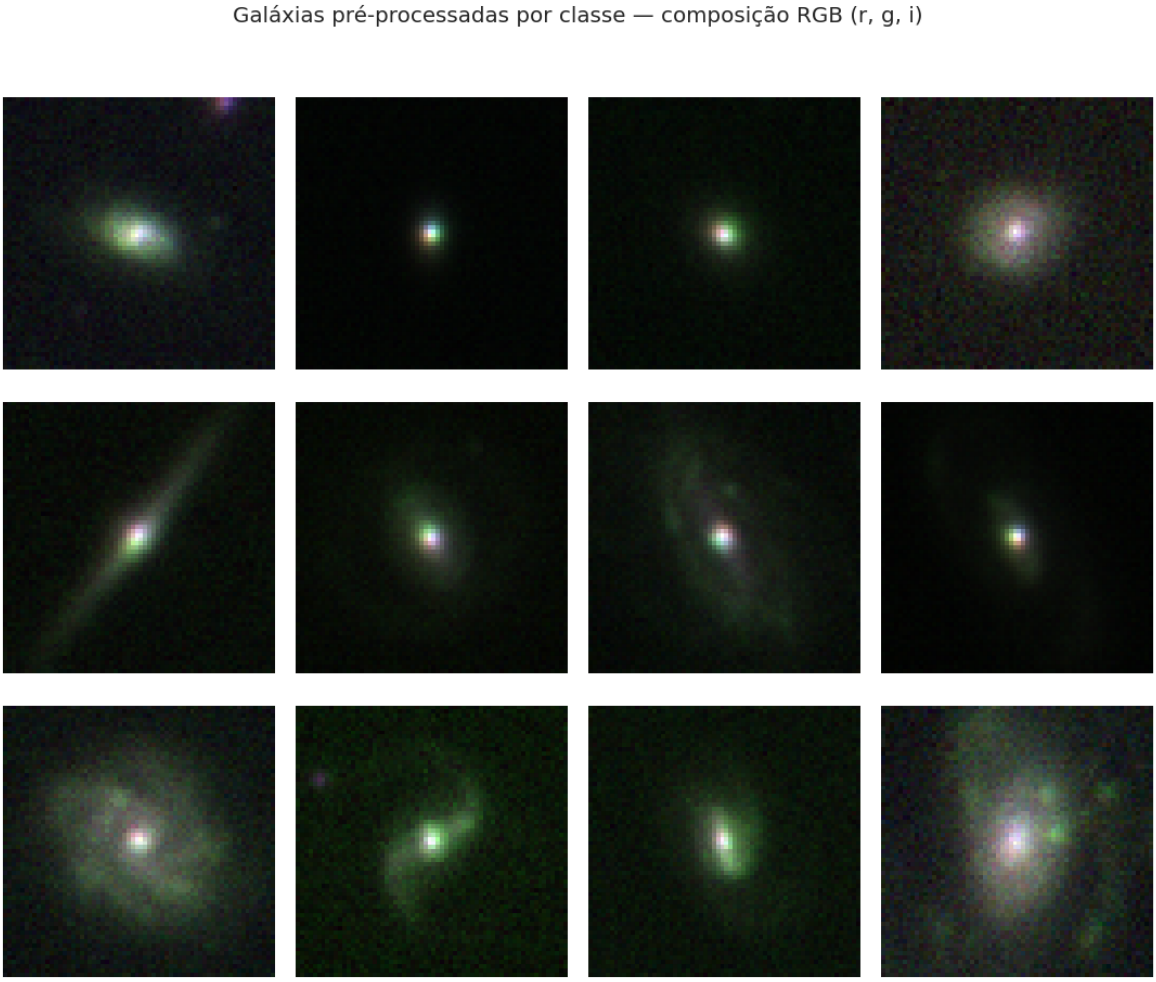

Figura 7: Grid de galáxias pré-processadas por classe morfológica, em composição RGB falsa-cor (r, g, i). Cada linha corresponde a uma classe e cada coluna a uma galáxia distinta.

4.3 Desempenho dos Modelos

4.3.1 MLP

As curvas de treinamento do MLP, na Figura 8, mostram convergência estável. A perda de validação cai rápido nas primeiras épocas, fica próxima de 0,37 e o mecanismo de parada antecipada, ou *EarlyStopping*, restaura os melhores pesos por volta da vigésima época. Nas primeiras iterações, a perda de validação fica abaixo da perda de treino. Esse efeito é esperado porque o *dropout* atua apenas durante o treinamento e penaliza, por isso, a métrica de treino.

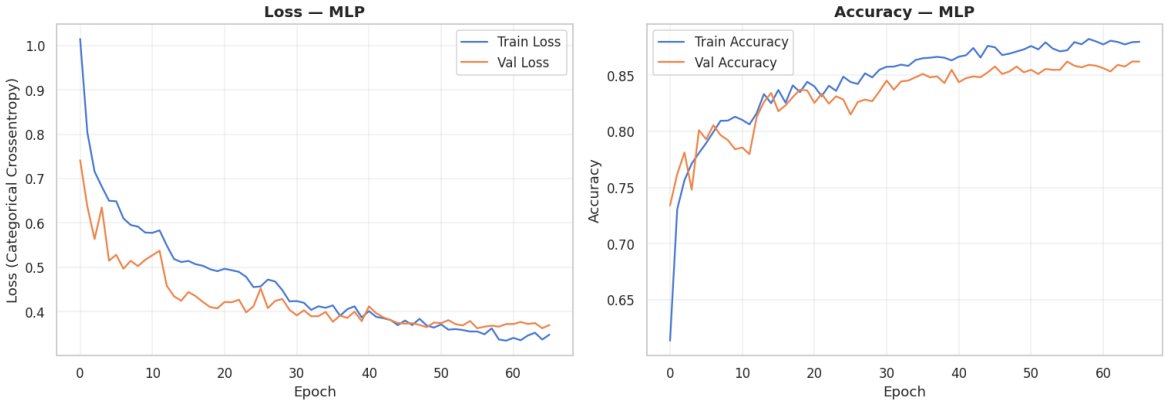

Figura 8: Curvas de perda (esquerda) e acurácia (direita) do MLP ao longo das épocas de treinamento.

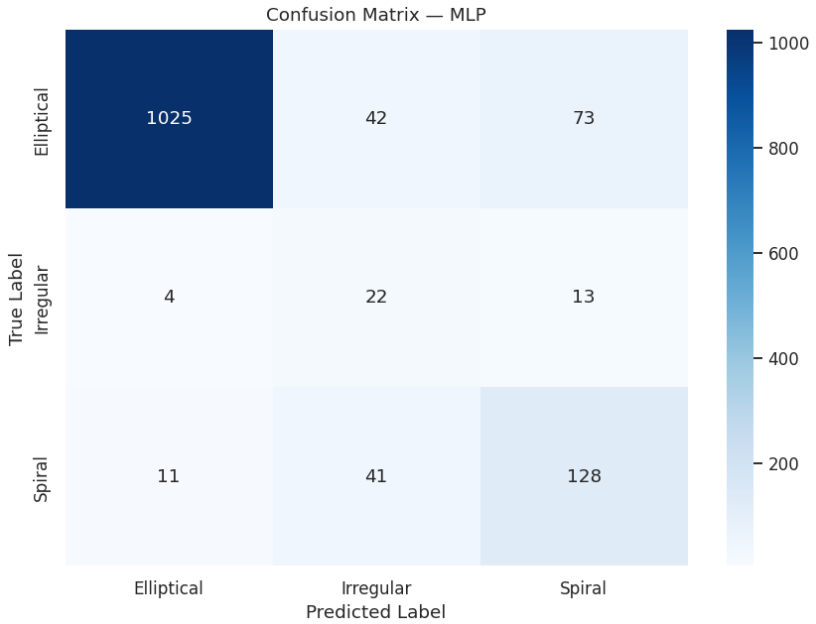

Figura 9: Matriz de confusão do modelo MLP no conjunto de teste.

O conjunto de teste reúne 1.359 galáxias, sendo 1.140 elípticas, 180 espirais e 39 irregulares. A matriz de confusão apresentada na Figura 9 mostra um comportamento típico de um classificador que usa apenas informação fotométrica. Das 39 irregulares, 22 são classificadas corretamente, a maior recuperação entre os três modelos. Em troca, a pureza cai bastante: 41 espirais e 42 elípticas também recebem o rótulo *Irregular*, e a confiabilidade da classe fica em apenas 0,210. O principal foco de erro está na confusão entre espirais e irregulares, duas classes que ocupam faixas parcialmente sobrepostas no espaço de cor e concentração. Sem informação visual, o MLP não consegue separá-las com segurança. Na classe Elliptical, a confiabilidade é de 0,986 e a completeza, de 0,899. Ou seja, quando o modelo prediz *Elliptical*, quase sempre acerta, mas deixa de identificar cerca de um décimo das elípticas reais.

4.3.2 CNN

O treinamento da CNN, ilustrado na Figura 11, é mais instável que o do MLP. Durante as 40 épocas, a perda de treino diminui gradualmente, enquanto a perda de validação oscila bastante e chega a um pico próximo de 5,0 por volta da época 36, voltando depois ao patamar anterior. Três fatores ajudam a explicar essa instabilidade. O primeiro é o aumento artificial de dados, ou *data augmentation*, exemplificado na Figura 10, que introduz variabilidade a cada *batch*. O segundo é o baixo número de exemplos nas classes raras, amplificado pelos pesos por classe, ou *class weights*. O terceiro é o tamanho reduzido do lote de validação, que torna a métrica sensível a poucos exemplos difíceis. A acurácia de validação, por outro lado, fica restrita a uma faixa estreita entre 0,85 e 0,90, o que indica que as oscilações afetam sobretudo a confiança probabilística das predições, e não a classe efetivamente atribuída.

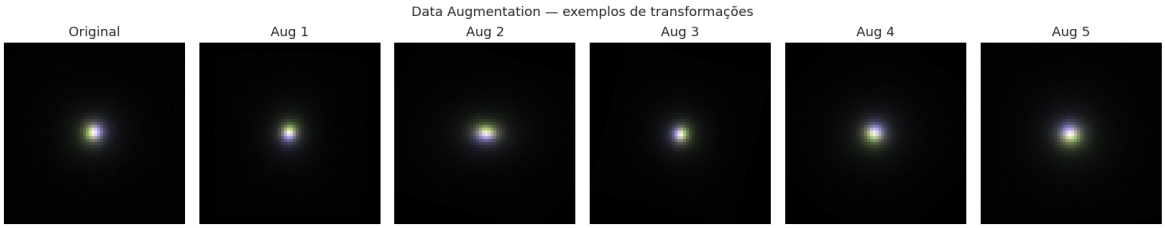

Figura 10: Exemplos de *data augmentation*: imagem original (esquerda) e versões transformadas por rotação, *flips* e variações de brilho.

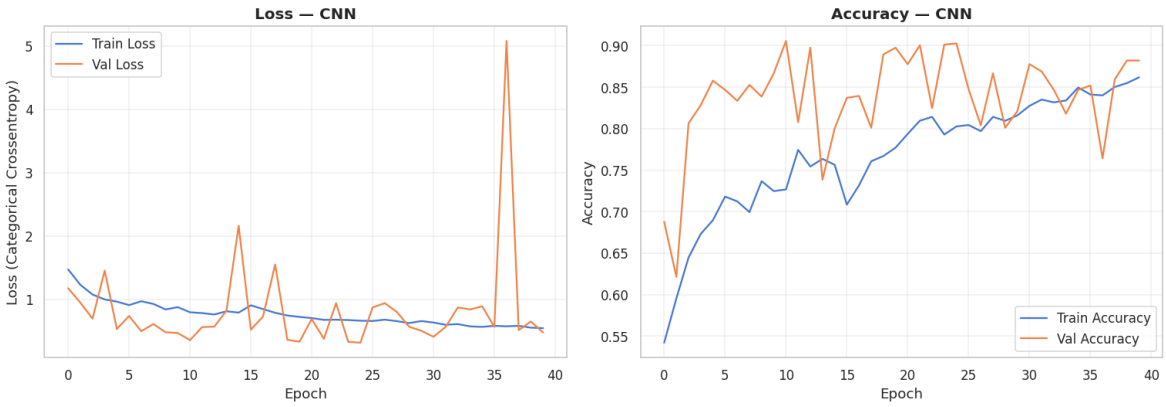

Figura 11: Curvas de perda e acurácia do modelo CNN.

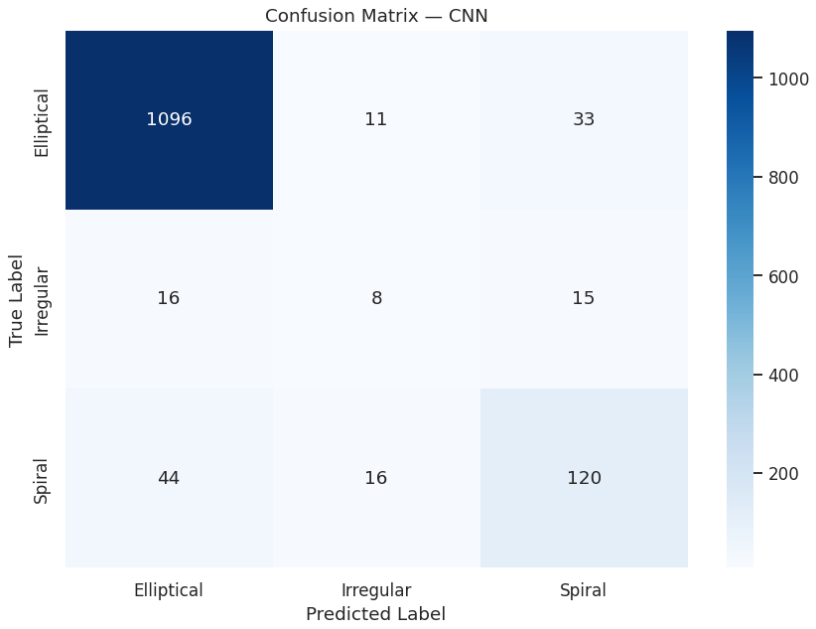

Figura 12: Matriz de confusão do modelo CNN no conjunto de teste.

A matriz de confusão correspondente, na Figura 12, mostra o efeito desse regime instável. Em comparação com o MLP, a CNN acerta 71 elípticas a mais, totalizando 1.096 contra 1.025, o que explica o ganho de cerca de 3,6 pontos percentuais em acurácia. Esse ganho, porém, se concentra na classe que já era a mais fácil de identificar. Nas demais, o desempenho não melhora ou piora: a rede recupera apenas 8 das 39 irregulares, contra 22 do MLP, e a completeza em *Spiral*, de 0,667, fica abaixo da obtida pelo modelo tabular, de 0,711. Na prática, a CNN é mais conservadora e atribui *Elliptical* a boa parte das galáxias com morfologia compacta e pouca estrutura visível, formato majoritário na amostra em resolução 64×64. O resultado é um F1-macro de 0,620, abaixo do MLP e típico de classificadores que trocam equilíbrio entre classes por acerto na classe dominante.

4.3.3 Modelo Híbrido

Ao juntar o ramo tabular ao convolucional, o treinamento do Híbrido, mostrado na Figura 13, volta a ser estável. A perda de validação converge em poucas épocas, o *EarlyStopping* encerra o ajuste em torno de 22 épocas e a diferença entre as curvas de treino e de validação fica pequena ao longo de todo o processo. O sinal tabular, formado por cor, concentração e dispersão de velocidades, funciona como uma referência de baixa variância que reduz o efeito do ruído das *features* visuais extraídas em baixa resolução.

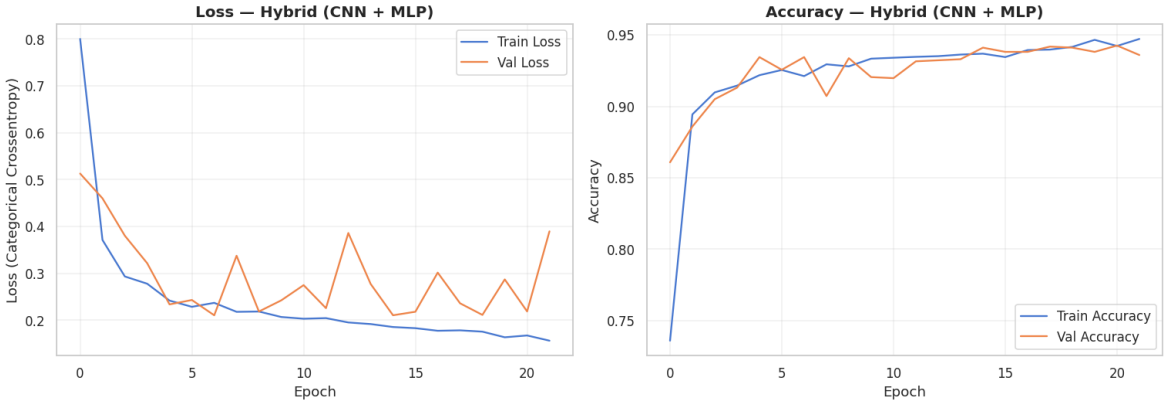

Figura 13: Curvas de treinamento do Híbrido (CNN + MLP).

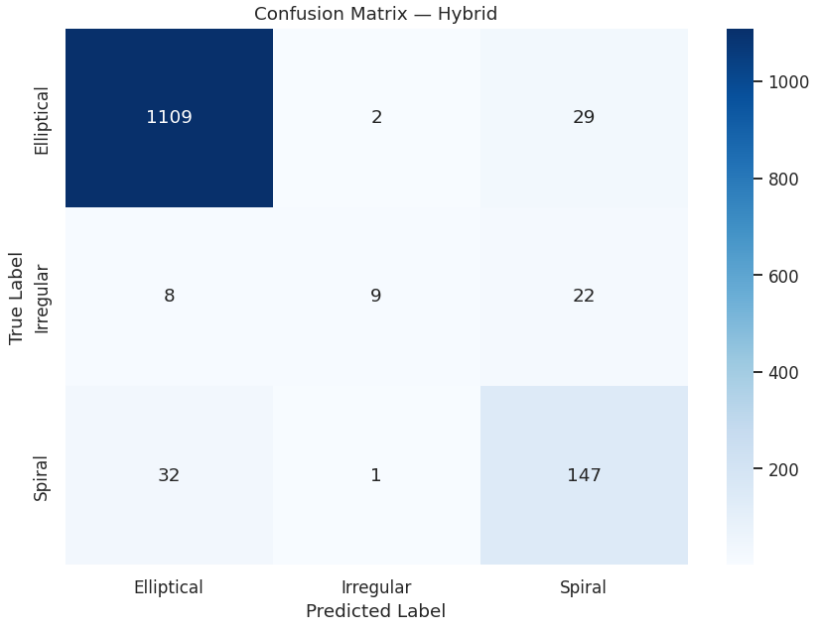

Figura 14: Matriz de confusão do Híbrido no conjunto de teste.

A matriz de confusão do Híbrido, apresentada na Figura 14, traz o melhor resultado entre os três modelos. O Híbrido classifica corretamente 1.109 elípticas, 147 espirais e 9 irregulares, totalizando 94 erros em 1.359 predições. Em comparação com a CNN isolada, o maior ganho ocorre na classe *Spiral*, com 27 espirais a mais classificadas corretamente, ou seja, 147 contra 120, sem aumento relevante de falsos positivos entre as elípticas. Na classe Irregular, o Híbrido age de forma oposta à do MLP: só atribui o rótulo *Irregular* quando há indícios fortes, o que gera apenas 12 predições nessa classe no conjunto de teste, das quais 9 são acertos. A confiabilidade resultante, de 0,750, é bem maior que as do MLP, de 0,210, e da CNN, de 0,229, e explica o valor de 0,700 em F1-macro, acima do MLP em mais de sete pontos. Em um cenário desbalanceado, o F1-macro premia o equilíbrio entre recuperação e pureza, que apenas o Híbrido consegue

manter em todas as classes.

4.4 Análise Comparativa

As métricas globais dos três modelos estão resumidas na Tabela 11 e a análise por classe, com as métricas astronômicas de completeza e confiabilidade, na Tabela 12. A Figura 15 compara graficamente as métricas globais, a Figura 16 apresenta as métricas por classe e a Figura 17 permite a comparação visual das matrizes de confusão dos três modelos.

Tabela 11: Métricas globais dos três modelos no conjunto de teste.

Modelo	**Acurácia**	**F1-macro**	**F1 ponderado**
MLP (tabular)	0,865	0,632	0,884
CNN (imagens)	0,901	0,620	0,898
Híbrido (CNN + MLP)	**0,931**	**0,700**	**0,926**

Tabela 12: Completeza (Revocação) e Confiabilidade (Precisão) por classe morfológica.

	Completeza (Revocação)			**Confiabilidade (Precisão)**		
Modelo	Ellip.	Irreg.	Spiral	Ellip.	Irreg.	Spiral
MLP	0,899	0,564	0,711	0,986	0,210	0,598
CNN	0,961	0,205	0,667	0,948	0,229	0,714
Híbrido	0,973	0,231	0,817	0,965	0,750	0,742

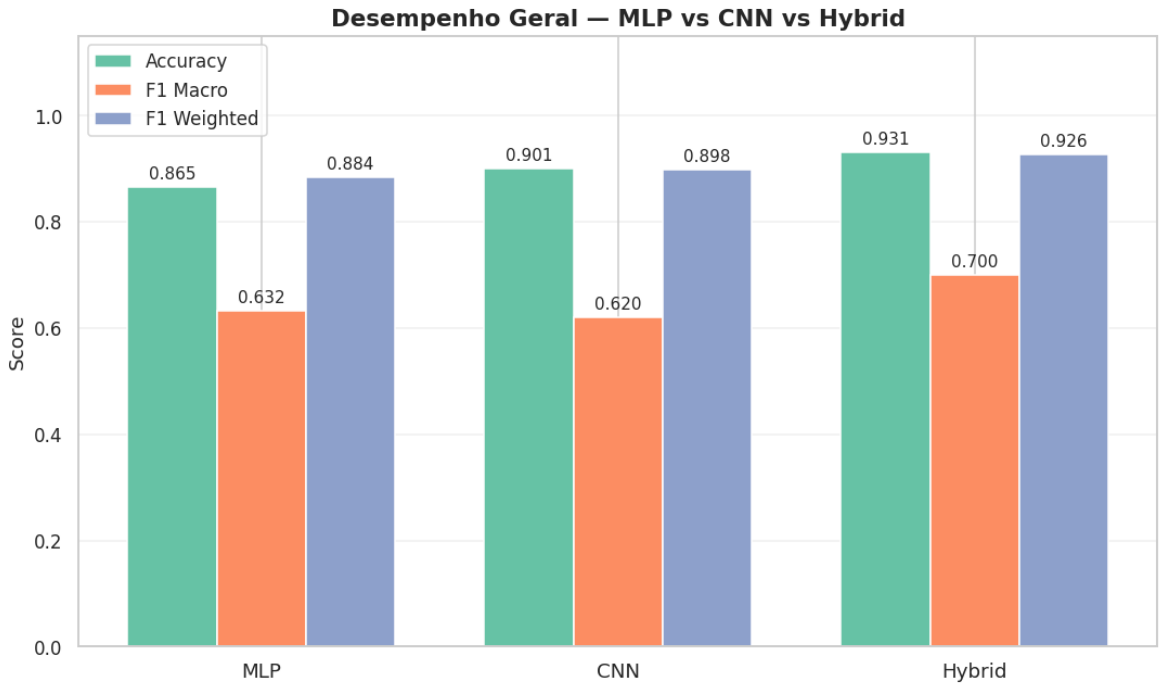

Figura 15: Comparação de acurácia, F1-macro e F1 ponderado entre os três modelos.

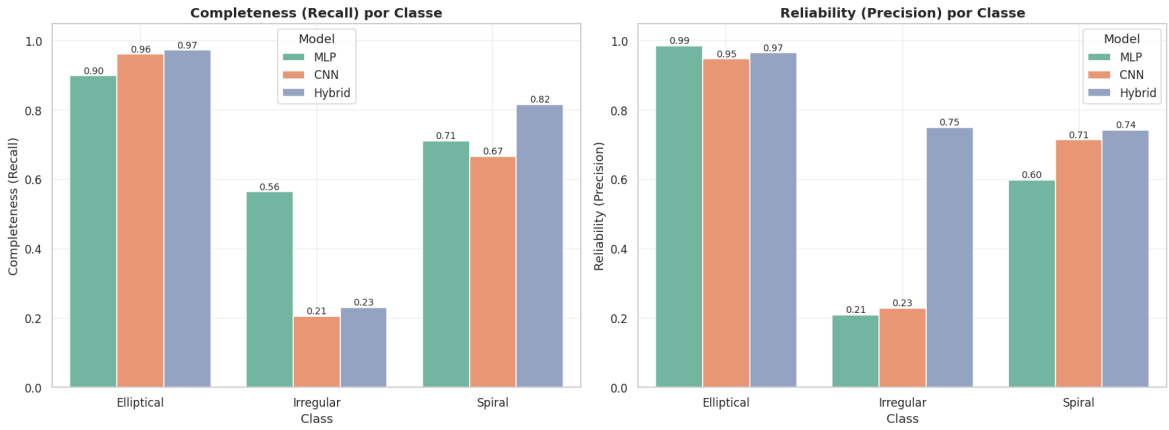

Figura 16: completeza e confiabilidade por classe morfológica e modelo.

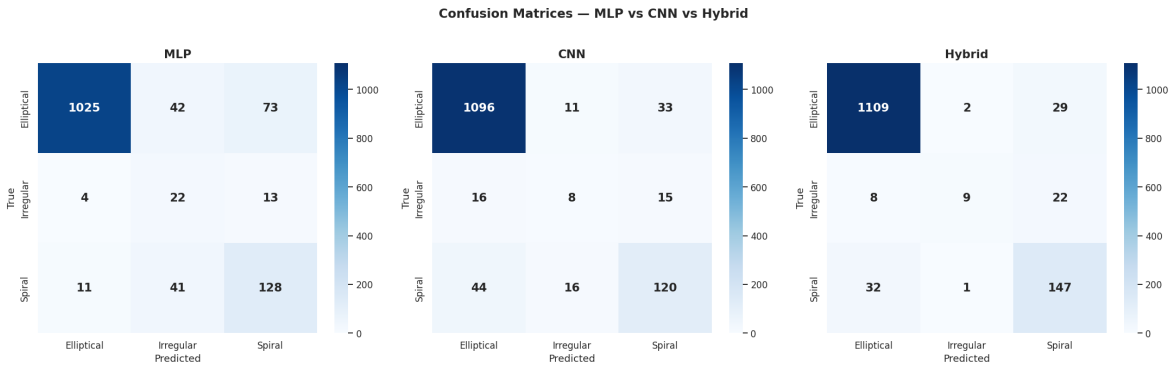

Figura 17: Matrizes de confusão dos três modelos na mesma escala de cor, permitindo comparação visual direta dos padrões de erro.

A Tabela 13 reúne a diagonal das três matrizes de confusão e permite ler, diretamente, o número de acertos por classe em relação ao total do conjunto de teste. Dessa comparação surgem três padrões. Primeiro, o desempenho nas elípticas cresce do MLP ao Híbrido, com ganho estável a cada incremento de informação. Em segundo lugar, as espirais não se beneficiam da CNN isolada e só apresentam melhora clara quando as duas modalidades são combinadas. Por fim, a classe Irregular continua sendo o ponto fraco das três arquiteturas: mesmo no melhor caso, pouco mais da metade dos exemplos é recuperada. O principal gargalo da classificação morfológica automática, portanto, está na classe rara, e não na classe dominante.

Tabela 13: Galáxias corretamente classificadas por classe (diagonal das matrizes de confusão) em relação ao total por classe no conjunto de teste.

Classe (total)	**MLP**	**CNN**	**Híbrido**
Elliptical (1.140)	1.025 (89,9%)	1.096 (96,1%)	**1.109 (97,3%)**
Spiral (180)	128 (71,1%)	120 (66,7%)	**147 (81,7%)**
Irregular (39)	**22 (56,4%)**	8 (20,5%)	9 (23,1%)
Total (1.359)	1.175 (86,5%)	1.224 (90,1%)	**1.265 (93,1%)**

A Tabela 14 relaciona o número aproximado de parâmetros de cada modelo com as métricas globais. A CNN tem cerca de 50 vezes mais parâmetros que o MLP, e o Híbrido soma, ao ramo convolucional, o ramo tabular e a camada de fusão. Do MLP para a CNN, a acurácia sobe de 0,865 para 0,901, um acréscimo de 3,6 pontos percentuais, mas o F1-macro recua de 0,632 para 0,620. Esse padrão mostra que o ganho de acerto global da CNN vem da classificação mais agressiva da classe majoritária, e não de uma melhora distribuída entre as demais. O Híbrido, com cerca de 700 mil parâmetros a mais do que a CNN, aumenta tanto a acurácia, que passa para 0,931, quanto o F1-macro, que chega

a 0,700. Esse resultado sugere que a combinação de informação visual e tabular produz um classificador mais equilibrado do que cada modalidade isolada.

Tabela 14: Relação entre complexidade dos modelos e desempenho.

Modelo	**Parâmetros**	**Acurácia**	**F1-macro**	**F1 ponderado**
MLP	∼47 mil	0,865	0,632	0,884
CNN	∼2,5 M	0,901	0,620	0,898
Híbrido	∼3,2 M	**0,931**	**0,700**	**0,926**

Olhar apenas para a acurácia seria enganoso neste caso. Um classificador trivial que classificasse todas as galáxias como *Elliptical* já chegaria a 0,839, o que reduz o intervalo útil de comparação entre modelos. É por isso que a CNN, mesmo superior ao MLP em acurácia, fica abaixo dele em F1-macro, com 0,620 contra 0,632: a métrica, baseada na média harmônica por classe, penaliza o comportamento que a acurácia premia, ou seja, ignorar as classes raras.

Ao cruzar as Tabelas 11, 12 e 13, o papel de cada modalidade fica mais claro. A fotometria pré-calculada pelo *pipeline* do SDSS carrega boa parte da informação morfológica útil. Por isso, o MLP, com cerca de 47 mil parâmetros, consegue uma *baseline* sólida e até supera, em F1-macro, uma CNN cinquenta vezes maior. A rota visual isolada ajuda sobretudo a refinar a fronteira entre elípticas e espirais, mas, sem o apoio das variáveis tabulares, tende a colapsar a classe Irregular sobre a majoritária. Só quando as duas modalidades são combinadas, como no Híbrido, o classificador se mantém preciso na classe dominante, competitivo na intermediária e parcimonioso, porém confiável, na classe rara. A escolha entre modelos depende, portanto, do *trade-off* desejado entre cobertura e pureza das classes minoritárias: o MLP prioriza a cobertura, o Híbrido prioriza a pureza, e a CNN isolada não é a melhor opção em nenhuma das duas dimensões.

4.5 Interpretabilidade

A Figura 18 mostra que o ramo convolucional do Híbrido produz padrões de ativação diferentes para cada classe morfológica. Nas elípticas, os mapas se concentram na região central, em linha com o perfil de brilho suave e dominado pelo bulge. Nas espirais, a ativação se estende ao longo do disco, com maior intensidade em regiões assimétricas, onde braços e núcleos de formação estelar produzem contraste local. Nas irregulares, os mapas ficam mais dispersos, o que é compatível com a morfologia fragmentada dessas galáxias.

Essa correspondência qualitativa é encorajadora, mas exige duas ressalvas. A primeira diz respeito à resolução das imagens, de 64×64 pixels, nas quais as galáxias ocupam poucas dezenas de pixels, o que limita a identificação de estruturas morfológicas finas mesmo para um observador humano. Os mapas de ativação atuam, portanto, sobre imagens com pouca informação estrutural. A segunda é de natureza metodológica: o Grad-CAM aponta as regiões que mais contribuem para a classe prevista, mas não é uma explicação causal formal e não garante correspondência direta entre as *features* aprendidas pela rede e propriedades físicas reais das galáxias.

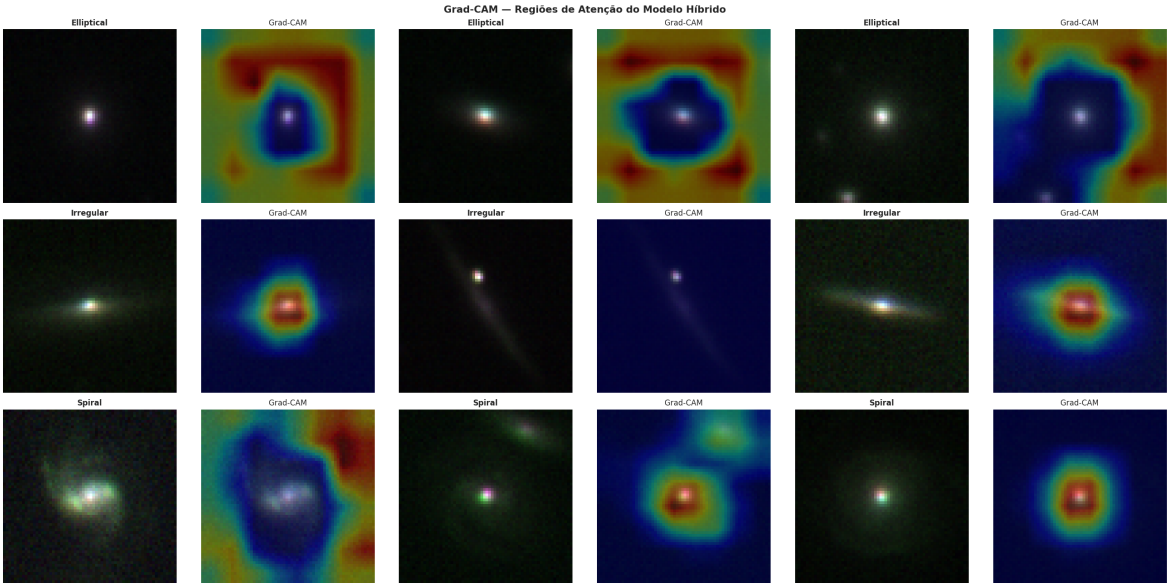

Figura 18: Grad-CAM do Híbrido para exemplos de cada classe morfológica. Cada par mostra a imagem RGB original (esquerda) e a sobreposição do mapa de calor Grad-CAM (direita). Regiões quentes indicam maior contribuição para a classificação.

4.6 Galáxias Mal Classificadas

A Figura 19 mostra exemplos de galáxias classificadas de forma errada pelo Híbrido, junto com o desvio padronizado de cada *feature* tabular em relação à média da classe predita. Três padrões de erro aparecem nos casos apresentados. No primeiro, uma galáxia espiral tem morfologia visual compacta e perfil suave, que a aproximam das elípticas, e suas *features* tabulares se afastam pouco dos valores típicos dessa classe. No segundo, uma irregular tem perfil fotométrico alongado, porém aproximadamente simétrico, com valores de concentração e cor compatíveis com elíptica, o que leva o modelo ao mesmo erro. No terceiro, uma irregular predita como espiral tem uma fonte compacta acompanhada de uma companheira próxima, padrão que sugere sistema em interação.

Em todos os casos, as *features* tabulares do objeto mal classificado ficam a menos de 2σ das médias da classe predita. Isso indica que os erros refletem ambiguidade real

entre morfologia e fotometria, e não ruído simples de rotulagem. O padrão é compatível com a incerteza dos próprios rótulos do Galaxy Zoo 2, cujo critério de consenso, com $f \geq 0{,}8$, já foi pensado para afastar os casos mais ambíguos do conjunto de treinamento.

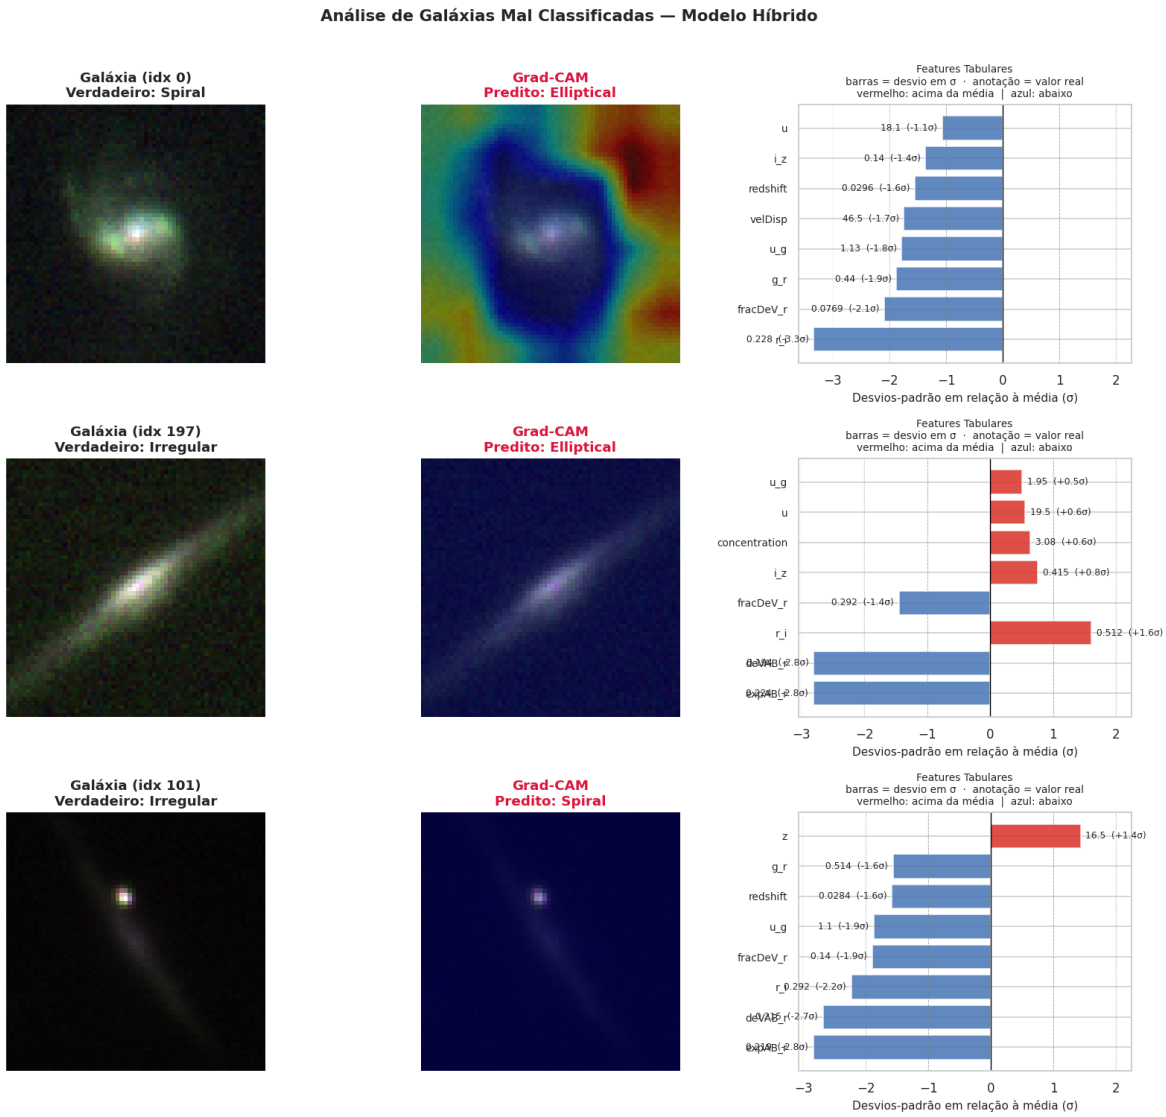

Figura 19: Exemplos de galáxias mal classificadas pelo Híbrido. Cada imagem indica a classe verdadeira (*True*) e a classe predita (*Pred*). Os casos representativos mostram morfologias ambíguas onde visual e fotometria apontam para classes distintas.

4.7 Limitações

Os resultados apresentados têm algumas limitações. A primeira é o desbalanceamento entre classes. Mesmo com o uso de *class weights*, a classe Irregular, com 261 exemplos no catálogo completo, continua sendo o principal gargalo dos três modelos. A segunda limitação é a estratégia de avaliação: todos os resultados vêm de uma única partição 70/15/15, gerada com semente fixa. Uma análise mais rigorosa em termos estatísticos

pediria validação cruzada estratificada, capaz de fornecer intervalos de confiança para as métricas. A terceira limitação está nos rótulos. Os dados do Galaxy Zoo 2, apesar da boa qualidade, carregam incerteza própria da classificação visual, e o critério adotado, com $f \geq 0{,}8$ e $N_{\text{votos}} \geq 20$, exclui uma parcela considerável de galáxias cuja classe seria ambígua. Reduzir esses limiares aumentaria a amostra, com o custo previsível de rótulos mais ruidosos.

5 Conclusão

O projeto GalaxyNet construiu um *pipeline* reprodutível de classificação morfológica de galáxias a partir de dados do SDSS DR17 e do Galaxy Zoo 2, implementou três arquiteturas de *deep learning* (MLP, CNN e Híbrido) e realizou a avaliação comparativa dos modelos sobre um conjunto de teste comum. O catálogo final contém 9.054 galáxias, descritas por 15 *features* tabulares e por imagens 64×64 nas bandas g, r e i.

A comparação entre os modelos mostra um padrão que não é trivial. Usando apenas as *features* tabulares, o MLP forneceu uma *baseline* com acurácia de 0,865 e F1-macro de 0,632, além da maior sensibilidade para a classe Irregular, com completeza de 0,564, ainda que com baixa precisão de 0,210. A CNN chegou a acurácia superior, de 0,901, mas F1-macro de 0,620, abaixo do MLP, o que mostra que a rede convolucional favorece a classe dominante e não generaliza bem para as irregulares. O Híbrido foi o único modelo que aumentou, ao mesmo tempo, a acurácia para 0,931, o F1-macro para 0,700 e o F1 ponderado para 0,926, além de obter a melhor completeza e confiabilidade nas espirais e a maior pureza nas irregulares, com confiabilidade de 0,750.

Esses resultados sugerem que, com os dados usados, a informação visual complementa as *features* fotométricas pré-calculadas e que a fusão tardia produz um classificador mais estável do que cada modalidade isolada. O fato de a CNN, sozinha, não superar o MLP em F1-macro indica que as variáveis tabulares carregam informação morfológica que as imagens brutas em baixa resolução não conseguem recuperar por conta própria. A análise Grad-CAM mostrou que as regiões de atenção do Híbrido são compatíveis com a morfologia esperada para cada classe, o que reforça, dentro dos limites da técnica, a interpretação de que as representações aprendidas refletem padrões astrofísicos plausíveis.

As limitações estão concentradas no desbalanceamento entre classes, no número reduzido de exemplos na classe Irregular (261 objetos) e no uso de uma única partição de treino, validação e teste. Como direções futuras, podem-se explorar técnicas de *transfer learning* a partir de modelos pré-treinados em catálogos maiores, como o Galaxy10 DECaLS, o uso de validação cruzada estratificada para estimar intervalos de confiança nas métricas e um ajuste dos limiares de consenso do Galaxy Zoo 2, com o objetivo de

ampliar a amostra das classes minoritárias.

Referências

[1] Hart, R. E. et al. (2016). *Galaxy Zoo 2: detailed morphological classifications for 304,122 galaxies from the Sloan Digital Sky Survey*. Monthly Notices of the Royal Astronomical Society, 445(4), 3466–3486. https://doi.org/10.1093/mnras/stu1816

[2] Conselice, C. J. (2003). *The Relationship between Stellar Light Distributions of Galaxies and Their Formation Histories*. The Astrophysical Journal Supplement Series, 147(1), 1–28. https://doi.org/10.1086/375001

[3] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). *SMOTE: Synthetic Minority Over-sampling Technique*. Journal of Artificial Intelligence Research, 16, 321–357. https://doi.org/10.1613/jair.953

[4] Lupton, R., Blanton, M. R., Fekete, G., et al. (2004). *Preparing Red-Green-Blue Images from CCD Data*. Publications of the Astronomical Society of the Pacific, 116(816), 133–137. https://doi.org/10.1086/382245

[5] Selvaraju, R. R., Cogswell, M., Das, A., et al. (2017). *Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization*. International Conference on Computer Vision (ICCV), 618–626. https://doi.org/10.1109/ICCV.2017.74

[6] Abdurrouf et al. (2022). *The Seventeenth Data Release of the Sloan Digital Sky Surveys: Complete Release of MaNGA, MaStar, and APOGEE-2 Data*. The Astrophysical Journal Supplement Series, 259(2), 35. https://doi.org/10.3847/1538-4365/ac4414

[7] Dieleman, S., Willett, K. W., & Dambre, J. (2015). *Rotation-invariant convolutional neural networks for galaxy morphology prediction*. Monthly Notices of the Royal Astronomical Society, 450(2), 1441–1459. https://doi.org/10.1093/mnras/stv632

[8] Kingma, D. P. & Ba, J. (2015). *Adam: A Method for Stochastic Optimization*. International Conference on Learning Representations (ICLR). https://arxiv.org/abs/1412.6980

[9] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press. Capítulo 8: Optimization for Training Deep Models. https://www.deeplearningbook.org

[10] Simonyan, K. & Zisserman, A. (2015). *Very Deep Convolutional Networks for Large-Scale Image Recognition*. International Conference on Learning Representations (ICLR). https://arxiv.org/abs/1409.1556

[11] Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). *Dropout: A Simple Way to Prevent Neural Networks from Overfitting*. Journal of Machine Learning Research, 15(56), 1929–1958. https://jmlr.org/papers/v15/srivastava14a.html

[12] Hubble, E. P. (1926). *Extragalactic Nebulae*. Astrophysical Journal, 64, 321–369. https://ui.adsabs.harvard.edu/abs/1926ApJ....64..321H

[13] de Vaucouleurs, G. (1959). *Classification and Morphology of External Galaxies*. In: Handbuch der Physik, ed. S. Flügge (Berlin: Springer), 53, 275.

[14] Conselice, C. J. (2014). *The Evolution of Galaxy Structure Over Cosmic Time*. Annual Review of Astronomy and Astrophysics, 52, 291–337. https://doi.org/10.1146/annurev-astro-081913-040037

[15] Kravtsov, A. V. & Borgani, S. (2012). *Formation of Galaxy Clusters*. Annual Review of Astronomy and Astrophysics, 50, 353–409. https://doi.org/10.1146/annurev-astro-081811-125502

[16] Allen, S. W., Evrard, A. E., & Mantz, A. B. (2011). *Cosmological Parameters from Observations of Galaxy Clusters*. Annual Review of Astronomy and Astrophysics, 49, 409–470. https://doi.org/10.1146/annurev-astro-081710-102514

[17] Dressler, A. (1980). *Galaxy Morphology in Rich Clusters: Implications for the Formation and Evolution of Galaxies*. Astrophysical Journal, 236, 351–365. https://doi.org/10.1086/157753

[18] Postman, M. & Geller, M. J. (1984). *The Morphology-Density Relation: The Group Connection*. Astrophysical Journal, 281, 95. https://ui.adsabs.harvard.edu/abs/1984ApJ...281...95P

[19] Dressler, A., Oemler, A. J., Couch, W., et al. (1997). *Evolution since $z = 0.5$ of the Morphology-Density Relation for Clusters of Galaxies*. Astrophysical Journal, 490, 577. https://doi.org/10.1086/304890

[20] Boselli, A., Fossati, M., & Sun, M. (2022). *Ram Pressure Stripping in High-Density Environments*. The Astronomy and Astrophysics Review, 30, 3. https://doi.org/10.1007/s00159-022-00140-3

[21] Peng, Y., Maiolino, R., Cochrane, R., et al. (2010). *Mass and Environment as Drivers of Galaxy Evolution in SDSS and zCOSMOS and the Origin of the Schechter Function*. Astrophysical Journal, 721, 193–221. https://doi.org/10.1088/0004-637X/721/1/193

[22] Nair, P. B. & Abraham, R. G. (2010). *A Catalog of Detailed Visual Morphological Classifications for 14,034 Galaxies in the Sloan Digital Sky Survey*. Astrophysical Journal Supplement Series, 186, 427. https://doi.org/10.1088/0067-0049/186/2/427

[23] Lintott, C. J., Schawinski, K., Slosar, A., et al. (2008). *Galaxy Zoo: Morphologies Derived from Visual Inspection of Galaxies from the Sloan Digital Sky Survey*. Monthly Notices of the Royal Astronomical Society, 389, 1179. https://doi.org/10.1111/j.1365-2966.2008.13689.x

[24] Willett, K. W., Lintott, C. J., Bamford, S. P., et al. (2013). *Galaxy Zoo 2: Detailed Morphological Classifications for 304,122 Galaxies from the Sloan Digital Sky Survey*. Monthly Notices of the Royal Astronomical Society, 435, 2835–2860. https://doi.org/10.1093/mnras/stt1458

[25] Domínguez Sánchez, H., Huertas-Company, M., Bernardi, M., Tuccillo, D., & Fischer, J. L. (2018). *Improving Galaxy Morphologies for SDSS with Deep Learning*. Monthly Notices of the Royal Astronomical Society, 476, 3661–3676. https://doi.org/10.1093/mnras/sty338

[26] Walmsley, M., Lintott, C., Geréb, K., et al. (2022). *Galaxy Zoo DECaLS: Detailed Visual Morphology Measurements from Volunteers and Deep Learning for 314,000 Galaxies*. Monthly Notices of the Royal Astronomical Society, 509, 3966–3988. https://doi.org/10.1093/mnras/stab2093

[27] Huertas-Company, M. & Lanusse, F. (2023). *The DAWES Review 10: The Impact of Deep Learning for the Analysis of Galaxy Surveys*. Publications of the Astronomical Society of Australia, 40, e001. https://doi.org/10.1017/pasa.2022.55

[28] York, D. G. et al. (2000). *The Sloan Digital Sky Survey: Technical Summary*. Astronomical Journal, 120, 1579–1587. https://doi.org/10.1086/301513

[29] Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley Publishing Company, Reading, MA.